

## 1、数据

使用samtools view 取 经过PCR验证的11000左右个位点 ( 包括得证和未得证的位点 ) 前后200bp的reads , 生成fastq文件 , 共1.3Gb。其中去除的reads绝大部分都是不配对的 , 所以后续质控及比对都是按照SE 的方法处理的。

已验证的位点去除重复后统计 , 共6269个位点得证 , 345个位点未得证。

## 2、使用初始参数处理 ( 5.1之前流程中的参数 )

已得证的位点共检出5189个 , 未得证的位点共检出87个。

PS：这一步的检出率都比较低，可能是以下几个方面的影响：

- a、取出来的reads 不是配对的，在比对、去重复、GATK处理的时候有影响。
- b、同一个位点附近的reads 可能来自不同的样本，相互之间有影响。（后针对未得证的位点，每个位点附近500bp内只取一个样本的数据，取出来的reads再处理，结果没有变化，所以可以排除这个因素）
- c、未得证位点附近结构比较复杂，改变参数后，报出的位点再验证的位点附近。这方面的影响较大，核查了十几个位点，有一半是这种情况。
- d、样本来自于不同时期，可能是不同的测序平台，对结果可能有影响。

## 3、GATK base quality 调整

添加--min\_base\_quality\_score 15 :

已得证的位点共检出5187个 , 未得证的位点共检出84个。

添加--min\_base\_quality\_score 25 :

已得证的位点共检出5180个 , 未得证的位点共检出77个。

## 4、使用fastp软件对reads进行过滤

fastp 参数 :

```
-q 20 -u 20 \ # 质量值低于20的标记为低质量，低质量占比大于20%的reads去掉  
-n 3 \ #去掉模糊碱基N数目大于3的序列  
-f 2 \ #切除reads5' 端 2个碱基  
-l 35 \ #去除质控后长度小于35的序列  
-W 8 \ #滑动窗口长度设为8bp  
-M 25 \ #滑动窗口内平均碱基质量低于25的从窗口起始位置剪切掉  
-3 \ #从reads末端进行滑动窗口的剪切  
-y \ #开启低复杂度过滤  
-x \ #trim 3' 端ploy结构  
-A \ #关闭去接头的操作 , , , 因为取出来的reads是经过质控的，且是不配对的序列，对fastp过滤接头有影响，故关闭
```

在设置--min\_base\_quality\_score 25 的情况下 :

已得证的位点共检出5169个 , 未得证的位点共检出72个。

## 5、参考序列补充未组装上染色体的序列

新参考序列路径 :

```
/share/ofs1a/prod/bin/heh_tmp/hg19Un/hg19_addUn.fa
```

在设置--min\_base\_quality\_score 15 的情况下 :

已得证的位点共检出5166个 , 未得证的位点共检出73个。

在设置--min\_base\_quality\_score 25 的情况下 :

已得证的位点共检出5159个 , 未得证的位点共检出67个。

PS : 曾尝试将hg38中未组装的序列添加进参考序列 , 但是已得证的位点损失太严重 , 故舍弃。

## 6、调整bwa参数

新的bwa参数

```
-M \ #mark shorter split hits as secondary 对后续去 PCR Duplicates 有帮助  
-B 8 \ #碱基错配罚分 默认4  
-O 12 \ #gap open 罚分 默认6  
-L 15 \ #penalty for 5'- and 3'-end clipping 默认 5  
-U 20 \ # penalty for an unpaired read pair [17]  
-T 50 \ #minimum score to output 默认30  
-d 75 \ #off-diagonal X-dropoff [100]  
-r 1.3 \ #look for internal seeds inside a seed longer than {-k} * FLOAT [1.5]  
-E 4 \ #gap延伸罚分 默认1  
-k 32\ #seed 长度
```

总体而言比对罚分更严格 , 为尽可能减少错误比对而设

测试结果 ( 使用新的参考序列 , 及质控后的序列 ) :

在设置--min\_base\_quality\_score 15 的情况下 :

已得证的位点共检出5173个 , 未得证的位点共检出73个。

在设置--min\_base\_quality\_score 25 的情况下 :

已得证的位点共检出5165个 , 未得证的位点共检出67个。

## 详细数据统计 :

GATK未更新	q15	q25	fastp	hg19_addUn&q15	hg19_addUn&q25	bwa&hg19_addUn&q15	bwa&hg19_addUn&q25
5189	5187	5180	5169	5166	5159	5173	5165
87	84	77	72	73	67	73	67

结论 :

- 1、gatk 添加--min\_base\_quality\_score 25 参数，参考序列添加未组装上基因组的序列 可以显著降低假阳性，并且对检出率影响不大
- 2、fastp 进一步质控对减低假阳性率有帮助，使用PEreads 的时候效果应该更明显
- 3、调整bwa参数后虽然假阳性率改善不明显，但是检出率有提升。

## 进一步调整GATK参数

GATK提供了很多对bam文件中reads进行过滤的方法，将这些方法添加进来进行测试。由于很多方法是基于PEreads 进行的。这次选用了未得证位点最多的10个样本的原始数据进行测试。

样本信息：

样本名称	57745	62528	65014	71648	53609	54610	67480	67483	71399	59387
不得证位点数目	4	4	4	4	5	5	5	5	5	6

测试参数：

### fastp

```
-f 5 -F 5 \
-g --poly_g_min_len 6 \
-x \
-3 \
-W 8 -M 25 \
-q 20 -u 20 \
-n 3 \
-y -Y 20 \
-c

#切除read1 , read2 5' 端各5bp
#切除reads末端的ployG结构 ( 大于6bp )
#切除reads末端的ployX结构 ( 10bp )
#从reads末端进行滑动窗口的剪切
#滑动窗口长度设为8bp ,滑动窗口内平均碱基质量低于25的从窗口起始位置剪切掉
# 质量值低于20的标记为低质量，低质量占比大于20%的reads去掉
#去掉模糊碱基N数目大于3的序列
#过滤低复杂度序列
#根据overlap 修正低质量的碱基
```

### bwa

```
-M \
#mark shorter split hits as secondary 对后续去 PCR Duplicates 有帮助
-B 8 \
#碱基错配罚分 默认4
-O 12 \
#gap open 罚分 默认6
-L 15 \
#penalty for 5'- and 3'-end clipping 默认 5
-U 20 \
# penalty for an unpaired read pair [17]
-T 50 \
#minimum score to output 默认30
-d 75 \
#off-diagonal X-dropoff [100]
-r 1.3 \
#look for internal seeds inside a seed longer than {-k} * FLOAT [1.5]
-E 4 \
#gap延伸罚分 默认1
-k 32 \
#seed 长度
```

### gatk添加的参数

```
-rf NotPrimaryAlignment \
-rf MaxInsertSize -maxInsert 1000 \
-rf BadCigar \
-rf BadMate \
--min_mapping_quality_score 30 \
-rf MateSameStrand
```

主要是添加了不同的reads filter，后来发现HaplotypeCaller 已默认添加了大部分reads filter：

## Additional Information

### Read filters

```
* HCMappingQualityFilter
* MalformedReadFilter
* BadCigarFilter
* UnmappedReadFilter
* NotPrimaryAlignmentFilter
* FailsVendorQualityCheckFilter
* DuplicateReadFilter
* MappingQualityUnavailableFilter
These Read Filters are automatically applied to the data by the Engine before processing by HaplotypeCaller.
```


测试详细数据见excel文档。

## 测试结果


10个样本共47个未得证位点，新参数处理过后，可排除35个位点。即可排除74.4%的假阳性位点。  
47个位点有部分比较集中，按100bp区域统计，共16个区域，可排除其中的12个。

其中67483xbycn1 和 59387xbycn1A 两个样本中的位点都未能排除，查看结果如下：

67483xbycn1 从比对结果上未见明显变异情况，不知为何会报出变异



59387xbycn1A call出来的变异与之前的差别较大，新参数显示这个位点插入 CCGAGAAGGGGGTTT，分析发现，主要是reads比对错误，将本不应该在这个位置的reads比对到这个位置，刚好reads末端无法比对上基因组。这个位点的QUAL非常低，应该可以在后期过滤掉。



针对上述情况，尝试添加GATK的过滤参数解决，但是没有效果，添加的参数：

```
-NoRequireSCBothEnds \
-filterTooShort 80 \
--dontUseSoftClippedBases
```

这个结果中没有对检出率进行分析，主要是数据中没有得证的检出位点，后续可以根据已知的高频位点进行估计。这次分析的样本量还是比较少，所以涉及的位点数目也不多，后续可以加大样本量进行测试。

